UNIVERSIDAD DE OVIEDO
ESCUELA POLITÉCNICA DE INGENIERÍA DE GIJÓN

TRABAJO DE FIN DE GRADO

Optimización de Algoritmos de Búsqueda en Grafos: Implementación y Comparación de Rendimiento en FPGA

Autor:
Alejandro Rodríguez López

Tutor:
Juan José Palacios Alonso

Memoria entregada en cumplimiento con los requisitos indicados por Trabajo de Fin de Grado de Grado de Ingeniería Informática en Tecnologías de la Información

22 de junio de 2024

UNIVERSIDAD DE OVIEDO

Resumen

Escuela Politécnica de Ingeniería de Gijón
Informática

Grado de Ingeniería Informática en Tecnologías de la Información

**Optimización de Algoritmos de Búsqueda en Grafos:
Implementación y Comparación de Rendimiento en FPGA**

por Alejandro Rodríguez López

La gran mayoría de ordenadores hoy en día poseen varios núcleos en sus procesadores, gracias a ellos se nos permite realizar diversas tareas de forma concurrente sin percatarnos de que un único procesador sólo puede hacer una tarea a la vez. La mayoría de programas deberían aprovechar este principio para acelerar y presentar resultados a sus usuarios más rápido.

En algunos casos esto no es así, generalmente porque sus desarrolladores no se han dignado a explorar los beneficios del paralelismo. No obstante, el simple uso de varios hilos no implica una mejora en rendimiento, el diseño del algoritmo y sus secciones paralelas son de crucial importancia para obtener beneficios tangibles.

Algunos algoritmos son más propensos al paralelismo, en ellos resulta más fácil hallar zonas en las que el uso de múltiples hilos: la implementación es sencilla y no existe mucho sobrecoste. Desafortunadamente esto no sucede en todos los algoritmos, en esta investigación se analiza el algoritmo A*, un claro ejemplo de cómo el paralelismo no siempre es garantía de rendimiento.

Índice general

Resumen I

1. Hipótesis de Partida y Alcance: *Estado del Arte* **1**
1.1. Objeto de la investigación . . . 1
1.2. Estado del arte . . . 1
1.3. Requisitos . . . 2
1.4. Alcance . . . 3

2. Problema a investigar: *Análisis, implementación y optimización* **4**
2.1. Job Shop Scheduling Problem . . . 4
2.2. Método a resolver . . . 5
2.2.1. Algoritmo . . . 5
2.2.1.1. Componentes A* . . . 5
2.2.1.2. Pseudocódigo . . . 7
2.2.2. Equipo de Estudio . . . 8
2.2.2.1. Arquitectura x86 . . . 8
2.2.2.2. FPGA . . . 8
2.3. Método de comparativas . . . 8
2.4. Implementación . . . 9
2.4.1. Task . . . 9
2.4.2. State . . . 9
2.5. Optimización . . . 10
2.5.1. A* . . . 10
2.5.1.1. State . . . 10
2.5.1.2. Coste H - Heurístico . . . 11
2.5.2. Paralelización . . . 12
2.5.2.1. First Come First Serve (FCFS) Solver . . . 12
2.5.2.2. Batch Solver . . . 15
2.5.2.3. Recursive Solver . . . 16
2.5.3. Hash Distributed A* (HDA*) Solver . . . 17

3. Experimentos: *Trabajo y Resultados* **18**
3.1. Conjuntos de datos . . . 18
3.1.1. *Jobshop Instances* . . . 18
3.1.2. Personalizados . . . 18
3.2. Método de medición . . . 18
3.3. Resultados . . . 20
3.4. Análisis . . . 20

4. Conclusiones: *Observaciones y Trabajos futuros* **21**

A. Código Fuente: **22**

B. Resultados y Métricas: **23**

Bibliografía **24**

Índice de figuras

2.1. Comparativa entre algoritmos Dijkstra y A* 5
2.2. Representación del algoritmo A* 13
2.3. Representación de la estrategia FCFS 14
2.4. Comparativa entre algoritmos monohilo y multihilo 14
2.5. Representación de la estrategia Batch 16

Índice de cuadros

Lista de Abreviaturas

CSV	**C**omma **S**eparated **V**alue
FCFS	**F**irst **C**ome **F**irst **S**erve
FPGA	**F**ield **P**rogrammable **G**ate **A**rray
HDA*	**H**ash **D**istributed **A***
HDL	**H**ardware **D**escription **L**anguage
HLS	**H**igh **L**evel **S**ynthesis
HTTP	**H**yper **T**ext **T**ransfer **P**rotocol
JSP	**J**ob **S**hop **P**roblem
JSSP	**J**ob **S**hop **S**cheduling **P**roblem
SoC	**S**ystem on **C**hip

Capítulo 1

Hipótesis de Partida y Alcance

Estado del Arte

1.1. Objeto de la investigación

El presente proyecto tiene como objetivo principal descubrir los beneficios del paralelismo aplicado al algoritmo A*. Para estudiar el rendimiento de las implementaciones desarrolladas se utilizará el Job Shop Scheduling Problem. Adicionalmente, se observará el rendimiento de una implementación de la misma solución en una FPGA.

La motivación principal para la realización de este proyecto emana en un interés personal por el diseño, implementación y optimización de algoritmos aplicables a problemas reales.

El Job Shop Scheduling Problem es un problema de optimización sobre la planificación de horarios. Este problema en particular es mundialmente conocido, ha sido resuelto utilizando un gran abanico de algoritmo diferentes y ha sido profundamente estudiado.

La resolución del Job Shop Scheduling Problem requiere el diseño e implementación de un algoritmo capaz de recibir como entrada las descripciones de una plantilla de trabajadores y un listado de trabajos y tareas a realizar puede ser aplicable en ámbitos industriales donde la automatización de la creación de planificaciones pueda ser de interés.

1.2. Estado del arte

Este proyecto abarca diversos tópicos, cuyas bibliografías (incluso en individual) tienen una gran extensión. A pesar de ello, resulta complicado hallar estudios previos sobre implementaciones paralelas del algoritmo A* enfocadas a la resolución del Job Shop Scheduling Problem utilizando FPGAs. Así pues, el punto de partida de este proyecto se compone principalmente de estudios sobre los distintos tópicos de forma individual.

El Job Shop Scheduling Problem tiene su origen en la década de 1960, desde entonces ha sido utilizado frecuentemente (incluso hasta el día de hoy) como herramienta de medición del rendimiento de algoritmos que sean capaces de resolverlo [Man67].

A lo largo de los años, se han realizado numerosos trabajos con el objetivo de recoger distintos algoritmos que resuelvan el problema. Dichos algoritmos provienen de diferentes ámbitos de la computación. Entre ellos se pueden encontrar búsquedas en grafos, listas de prioridad, ramificación y poda, algoritmos genéticos, simulaciones Monte Carlo o métodos gráficos como diagramas Gantt y Pert. [Yan77], [Nil69], [KTM99], [BC22].

El algoritmo A* fue diseñado a finales de la década de 1960 con el objetivo de implementar el enrutamiento de un robot conocido como *"Shakey the Robot"* [Nil84]. A* es una evolución del conocido algoritmo de Dijkstra frecuentemente utilizado también para la búsqueda en grafos. La principal diferencia entre estos dos algoritmos es el uso de una función heurística en el A* que 'guía' al algoritmo en la dirección de la solución. [HNR68], [MSV13], [Kon14].

El algoritmo A* no es propenso a la paralelización, no existe una implementación simple que aproveche el funcionamiento de varios procesadores de forma simultanea. En su lugar existen varias alternativas que paralelizan el algoritmo, cada una de ellas con sus fortalezas y debilidades. Estas diferentes versiones serán estudiadas, implementadas y probadas en esta investigación. [Zag+17], [WH16].

El tópico sobre el que menor cantidad de documentación existe y que supone una mayor curva de aprendizaje es sin lugar a duda la implementación del algoritmo A* en una FPGA. A diferencia de este proyecto, la principal fuente de bibliografía sobre este tópico desarrolla una implementación personalizada del algoritmo que reporta una aceleración de casi el 400%. [ZJW20].

1.3. Requisitos

El algoritmo a desarrollar en esta investigación deberá recibir como entrada una estructura de datos que contenga los trabajos, para cada trabajo la lista de tareas que lo compone, para cada tarea su duración y el listado de trabajadores cualificados para realizarla (generalmente, la longitud de esta lista será 1).

Como resultado, el algoritmo deberá retornar un listado de trabajos, para cada trabajo el instante de tiempo en el que se inicia cada una de sus tareas y un listado con los instantes de tiempo en los que cada trabajador quedará libre. El máximo elemento del listado de instantes de tiempo en los que cada trabajador queda libre se define como el *makespan*, el tiempo necesario para finalizar todos los trabajos.

1.4. Alcance

El presente documento describe el problema a resolver en detalle, los diferentes algoritmos implementados, observaciones sobre los mismos, casos de prueba utilizados para obtener métricas de rendimiento y observaciones sobre las métricas obtenidas.

Entre las observaciones tanto de los algoritmos como de las métricas obtenidas, se encontrarán razonamientos sobre los resultados así como explicaciones de las razones por las cuales un algoritmo presenta un rendimiento distinto a otro.

Capítulo 2

Problema a investigar

Análisis, implementación y optimización

2.1. Job Shop Scheduling Problem

Se estudia la implementación de una solución al problema *Job Shop Scheduling (JSP)* [Yan77] [1] resuelto utilizando el algoritmo A*. Como su nombre indica, se trata de un problema en el que se debe crear una planificación. Claramente, el JSP es un problema de optimización.

El JSP busca una planificación para una serie de máquinas (o trabajadores) que deben realizar un número conocido de trabajos. Cada trabajo está formado por una serie de operaciones (o tareas), con una duración conocida. Las tareas de un mismo trabajo deben ser ejecutadas en un orden específico.

Existen numerosas variantes de este problema, algunas permiten la ejecución en paralelo de algunas tareas o requieren que alguna tarea en específico sea ejecutada por un trabajador (o tipo de trabajador) en particular. Por ello, es clave denotar las normas que se aplicarán a la hora de resolver el problema JSP:

1. Existen un número natural conocido de trabajos.
2. Todos los trabajos tienen el mismo número natural conocido de tareas.
3. A excepción de la primera tarea de cada trabajo, todas tienen una única tarea predecesora que debe ser completada antes de iniciar su ejecución.
4. Cada tarea puede tener una duración distinta.
5. La duración de cada tarea es un número natural conocido.
6. Existe un número natural conocido de trabajadores.
7. Cada tarea tiene un trabajador asignado, de forma que sólo ese trabajador puede ejecutar la tarea.
8. Una vez iniciada una tarea, no se puede interrumpir su ejecución.
9. Un mismo trabajador puede intercalar la ejecución de tareas de diferentes trabajos.

[1] El problema también es conocido por otros nombres similares como *Job Shop Scheduling Problem (JSSP)* o Job Scheduling Problem (JSP).

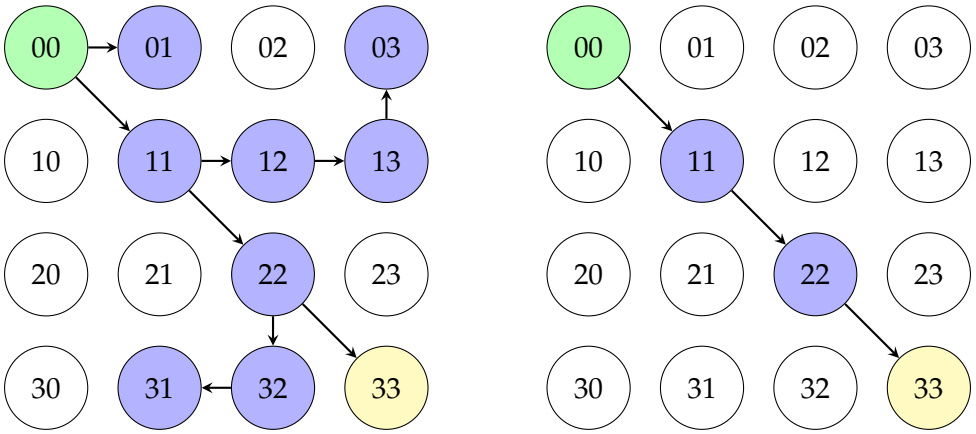

(A) Algoritmo Dijkstra (B) Algoritmo A*

FIGURA 2.1: Comparativa entre algoritmos Dijkstra y A*

10. Un trabajador sólo puede realizar una tarea al mismo tiempo.
11. Los tiempos de preparación de un trabajador antes de realizar una tarea son nulos.
12. Los tiempos de espera entre la realización de una tarea y otra son nulos.

2.2. Método a resolver

2.2.1. Algoritmo

Existen numerosos algoritmos capaces de resolver el problema del JSP. Estrategias más simples como listas ordenadas en función de la duración de los trabajos, algoritmos genéticos, técnicas gráficas, algoritmos *Branch and Bound* y heurísticos. En este estudio se utilizará un algoritmo heurístico, A* (*A star*) [HNR68] para resolver el problema JSP.

El A* es una evolución del algoritmo de Dijkstra. Su principal diferencia es la implementación de una función heurística que se utiliza para decidir el siguiente nodo a expandir. De esta forma, se podría decir que el algoritmo A* va 'guiado' hacia la solución, mientras que el algoritmo de Dijkstra sigue los caminos con menor coste (Véase figura 2.1).

El algoritmo A* utiliza varios componentes para resolver problemas de optimización. A continuación se describe cada uno de ellos.

2.2.1.1. Componentes A*

2.2.1.1.1. Estado

El estado es una estructura de datos que describe la situación del problema en un punto determinado. Estos estados deben ser comparables, debe ser posible dados dos estados conocer si son iguales o distintos. En el caso del JSP, el estado podría estar formado por la siguiente información:

- Instante de tiempo en el que comienza cada tarea planificada.
- Instante de tiempo futuro en el que cada trabajador estará libre (i.e. finaliza la tarea que estaba realizando).

El resultado final del JSP será un estado donde todas las tareas han sido planificadas.

2.2.1.1.2. Costes

El algoritmo A* utiliza 3 costes distintos para resolver el problema de optimización:

2.2.1.1.2.1. Coste G

El coste G (de ahora en adelante $cost_g$) es el coste desde el estado inicial hasta el estado actual. Este coste es calculado buscando el mayor tiempo de fin de las tareas ya planificadas.

2.2.1.1.2.2. Coste H

El coste H (de ahora en adelante $cost_h$) es el coste estimado desde el estado actual hasta el estado final. Este coste es calculado utilizando una función heurística, que estima el coste.

2.2.1.1.2.3. Coste F

El coste F (de ahora en adelante $cost_f$) es el coste estimado desde el estado inicial hasta el estado final pasando por el estado actual.

Por lo tanto,

$$cost_f = cost_g + cost_h$$

2.2.1.1.3. Generación de sucesores

El algoritmo A* debe generar un número de estados sucesores dado un estado cualquiera [2]. Por lo que será necesario una función que dado un estado retorne un listado de estados.

[2]Dependiendo de la implementación, puede existir alguna excepción a esta norma, como el estado objetivo que puede no tener sucesores.

Dado un estado donde existen N tareas por ejecutar ($T_0 \dots T_N$) y un trabajador cualquiera sin tarea asignada tendrá N estados sucesores. En cada uno, el trabajador libre tendrá asignada cada una de las tareas, desde T_0 hasta T_N [3].

2.2.1.1.4. Listas de prioridad

El algoritmo A* utiliza dos listas de estados: la lista abierta y la lista cerrada. La lista cerrada contiene los estados que ya han sido estudiados mientras que la lista abierta contiene los estados que aún están por estudiar.

Cada vez que se estudia un estado de la lista abierta, se obtienen sus sucesores que son añadidos a la lista abierta (siempre y cuando no estén en la lista cerrada) mientras que el estado estudiado pasa a la lista cerrada.

Los estados de la lista abierta están ordenados en función de su $cost_f$, de menor a mayor. De esta forma, se tiene acceso inmediato al elemento con menor $cost_f$.

2.2.1.2. Pseudocódigo

```
1     lista_abierta = SortedList()
2     lista_abierta.append(estado_inicial)
3
4     g_costes = {}
5     f_costes = {}
6
7     g_costes[estado_inicial] = 0
8     f_costes[estado_inicial] = calcular_h_coste(estado_inicial)
9
10    while (not lista_abierta.empty()):
11        estado_actual = lista_abierta.pop()
12
13        if (estado_actual == estado_final):
14            return estado_actual
15
16        estados_sucesores = calcular_sucesores(estado_actual)
17
18        for estado_sucesor in estados_sucesores:
19            sucesor_g_coste = calcular_g_coste(estado_sucesor)
20            if (sucesor_g_coste < g_costes[estado_sucesor]):
21                g_costes[estado_sucesor] = sucesor_g_coste
22                f_costes[estado_sucesor] = sucesor_g_coste +
    calcular_h_coste(estado_sucesor)
23                if (estado_sucesor not in lista_abierta):
24                    lista_abierta.append(estado_sucesor)
```

[3] Suponiendo que:

1. Todas las tareas $T_x \in (T_0 \dots T_N)$ pueden ser ejecutadas por el trabajador libre.
2. Todas las tareas $T_x \in (T_0 \dots T_N)$ pueden ser ejecutadas en este instante (e.g. cada una es de un trabajo diferente).

2.2.2. Equipo de Estudio

Este algoritmo es implementado y optimizado en diversas arquitecturas. Posteriormente, se realizan comparaciones entre ellas.

2.2.2.1. Arquitectura x86

Inicialmente, se realiza una implementación del algoritmo utilizando **Python** . Esta versión permite comprobar rápidamente el correcto funcionamiento del mismo así como llevar a cabo pruebas rápidas sin necesidad de compilación y estudiar los posibles cuellos de botella del algoritmo.

Posteriormente, se desarrolla una nueva versión del mismo algoritmo utilizando C++, un lenguaje compilado, imperativo y orientado a objetos que facilita la paralelización gracias a librerías como OpenMP.

Una vez desarrolladas ambas versiones monohilo, se comienza la implementación de versiones multihilo que serán posteriormente comparadas.

2.2.2.2. FPGA

Finalmente, se desarrolla una implementación del algoritmo diseñado para ser ejecutado en una FPGA. Esta aceleradora, se encuentra embebida en una placa SoC Zybo Z7 10 acompañada de un procesador ARM.

Para realizar esta implementación, se utiliza el software propio de Xilinx (AMD), Vitis HDL. Este programa ofrece entre muchas otras herramientas un sintetizador capaz de transpilar código C++ a Verilog que puede ser entonces compilado para ejecutarse en la FPGA.

2.3. Método de comparativas

Las comparativas entre las diferentes implementaciones del algoritmo se realizan en base a varias características. Principalmente:

1. Tiempo de ejecución.
2. Calidad de la solución.

Como es lógico, el algoritmo es ejecutado utilizando distintos datos de entrada múltiples veces.

NOTA

La segunda ejecución de cualquier algoritmo suele tender a requerir menos tiempo debido al funcionamiento de la caché.
Para evitar este fenómeno, el algoritmo se ejecuta siempre N veces ignorando las métricas de la primera ejecución.

2.4. Implementación

Tanto **Python** como C++ son lenguajes orientados a objetos. Esta sección contiene las descripciones de las diferentes clases diseñadas para dar soporte al algoritmo.

2.4.1. Task

La clase `Task` correspone a una tarea a realizar. Una instancia de esta clase está definida por los atributos:

- `unsigned int duration`: Duración de la tarea.
- `std::vector<int> qualified_workers`: Listado de trabajadores que pueden realizar la tarea.

2.4.2. State

La clase `State` corresponde a un estado (o nodo). Una instancia de esta clase está definida por los atributos:

- `std::vector<std::vector<Task>> jobs`: Lista de trabajos y tareas a ejecutar.
- `std::vector<std::vector<int>> schedule`: Planificación actual.
- `std::vector<int> workers_status`: Instantes en los que cada trabajador queda libre.

NOTA

Nótese que el atributo `std::vector<std::vector<Task>> jobs` será el mismo en todos los estados de un mismo problema. Por lo que no será necesario revisarlo en `State::operator==` ni `State::operator()`. Si el consumo de memoria fuese de importancia, sería posible utilizar una referencia para evitar almacenar esta estructura múltiples veces.

El algoritmo A* requiere que se creen estructuras de datos que contendrán instancias de la clase `State`. Estas estructuras necesitan que se proporcionen implementaciones para los operadores `State::operator==` y `State::operator()` de la clase `State`. Para diseñar las implementaciones de estos operadores se estudian previamente los atributos que componen la clase `State`:

- `std::vector<std::vector<Task>> jobs`: Es igual en todas las instancias de `State`, por lo que será ignorado.
- `std::vector<std::vector<int>> schedule`: Proporciona información crucial sobre el estado ($cost_g$ y $cost_h$).
- `std::vector<int> workers_status`: No proporciona información alguna sobre los costes, pero es necesario para distinguir dos estados diferentes ya que es posible que dos estados tengan los mismos costes pero a través de planificaciones distintas.

Por ello, será necesario definir dos operadores `State::operator()`: uno que sea indiferente al atributo `std::vector<int> workers_status` (`StateHash::operator()`) y otro que sí lo tenga en cuenta para distinguir diferentes instancias de `State` (`FullHash::operator()`).

2.5. Optimización

2.5.1. A*

La siguiente subsección estudia la optimización del algoritmo A* sin tener en cuenta el paralelismo, esto es, se trata de optimizar el rendimiento monohilo del mismo.

2.5.1.1. State

La operación `operator()` es ejecutada varias veces para cada `State`, este método tiene una complejidad de $O(n^2)$, por lo que su valor se almacena tras calcularlo por primera vez en un atributo del propio `State`.

La operación `operator()` contiene 2 bucles `for` anidados. Su principal objetivo es calcular una reducción de los atributos de la instancia `State`. Se utiliza `#pragma omp parallel for collapse(2) reduction(+: seed)` para paralelizar la reducción.

```
1  std::size_t FullHash::operator()(State key) const
2  {
3      if (key.get_full_hash() != UNINITIALIZED_HASH)
4          return key.get_full_hash();
5      std::vector<std::vector<int>>
6          schedule = key.get_schedule();
7      std::vector<int> workers_status = key.get_workers_status();
8      std::size_t seed = schedule.size() * schedule[0].size() *
       workers_status.size();
9
10 #pragma omp parallel for reduction(+ : seed)
11     for (size_t i = 0; i < workers_status.size(); i++)
12         seed += (workers_status[i] * 10 ^ i);
13
14     if (schedule.empty())
15         return seed;
16
```

```
17      const std::size_t nTasks = schedule[0].size();
18  #pragma omp parallel for collapse(2) reduction(+ : seed)
19      for (size_t i = 0; i < schedule.size(); i++)
20      {
21          for (size_t j = 0; j < nTasks; j++)
22              seed += (schedule[i][j] * 10 ^ ((1 + i + workers_status.
        size()) * j + j));
23      }
24      key.set_full_hash(seed);
25      return seed;
26  }
```

LISTING 2.1: Implementación de `FullHash::operator()`

Los operadores `operator==` necesarios se implementan utilizando los `operator()` correspondientes.

NOTA

Las funciones hash utilizadas en los `operator()` son resistentes a colisiones, esto es, $h(State_a) \neq h(State_b) \iff State_a \neq State_b$ por lo que se pueden utilizar para comparar elementos en `operator==`.

2.5.1.2. Coste H - Heurístico

La principal decisión que afectará al tiempo de ejecución del algoritmo se encuentra en la Implementación de la función heurística encargada de calcular el coste H. Este coste se utiliza para seleccionar el siguiente nodo a expandir, por lo que un buen heurístico es aquel que mejor dirige al algoritmo en la dirección del nodo objetivo.

El rendimiento y calidad del resultado del algoritmo dependerán en gran medida de la función seleccionada. En algunos casos la implementación retornará resultados óptimos (o cercanos al óptimo) pero requerirá un mayor tiempo de ejecución, mientras que otras implementaciones requerirán un menor tiempo de ejecución pero sus resultados no serán óptimos. Dependiendo del problema a resolver será conveniente implementar una función heurística de un tipo u otro.

2.5.1.2.1. Heurístico para optimalidad

La siguiente implementación de la función heurística dirigirá al algoritmo hacia nodos solución que sean óptimos o se encuentren relativamente cerca del óptimo.

```
1  unsigned int State::calculate_h_cost() const
2  {
3      std::vector<int> h_costs;
4      for (size_t job_idx = 0; job_idx < this->m_jobs.size(); job_idx++)
5      {
6          h_costs.emplace_back(0);
7          std::vector<Task> job = this->m_jobs[job_idx];
8          for (size_t task_idx = 0; task_idx < job.size(); task_idx++)
9              if (this->get_schedule()[job_idx][task_idx] == -1)
10                 h_costs[job_idx] += job[task_idx].get_duration();
```

```
11      }
12      auto max_element = std::max_element(h_costs.begin(), h_costs.end())
        ;
13      return max_element == h_costs.end() ? 0 : *max_element;
14  }
```

La función calcula el tiempo necesario para completar cada trabajo y retorna el tiempo mayor.

2.5.1.2.2. Heurístico para tiempo

La siguiente implementación de la función heurística dirigirá al algoritmo hacia cualquier nodo solución independientemente de si es óptimo o no.

```
1  unsigned int State::calculate_h_cost() const
2  {
3      unsigned int unscheduled_tasks_count = 0;
4      for (std::size_t job_idx = 0; job_idx < this->m_jobs.size();
       job_idx++)
5          for (std::size_t task_idx = 0; task_idx < this->m_jobs[job_idx
       ].size(); task_idx++)
6              if (this->m_schedule[job_idx][task_idx] == -1)
7                  unscheduled_tasks_count += this->m_jobs[job_idx][
       task_idx].get_duration();
8      return unscheduled_tasks_count;
9  }
```

La función calcula el tiempo necesario para completar las tareas restantes si se ejecutasen una a una y retorna esta suma.

NOTA

A pesar de que ambas implementaciones tienen la misma complejidad ($O(n^2)$), un algoritmo A* utilizando de ellas tardará varias magnitudes de tiempo más que si utilizase la otra aunque retornará resultados notablemente mejores en algunos casos.

2.5.2. Paralelización

En la siguiente subsección se estudia la paralelización del algoritmo A*. Este estudio está compuesto por la descripción y comparación de distintas alternativas discutidas en la literatura.

2.5.2.1. First Come First Serve (FCFS) Solver

Sería posible desarrollar una implementación que paralelice el procesamiento de los nodos, asignando uno a cada hilo de forma que para N hilos se procesen N nodos de forma simultánea. Esta estrategia permite que los hilos procesen los nodos a medida que entran en el `open_set` (Véase Figura 2.3).

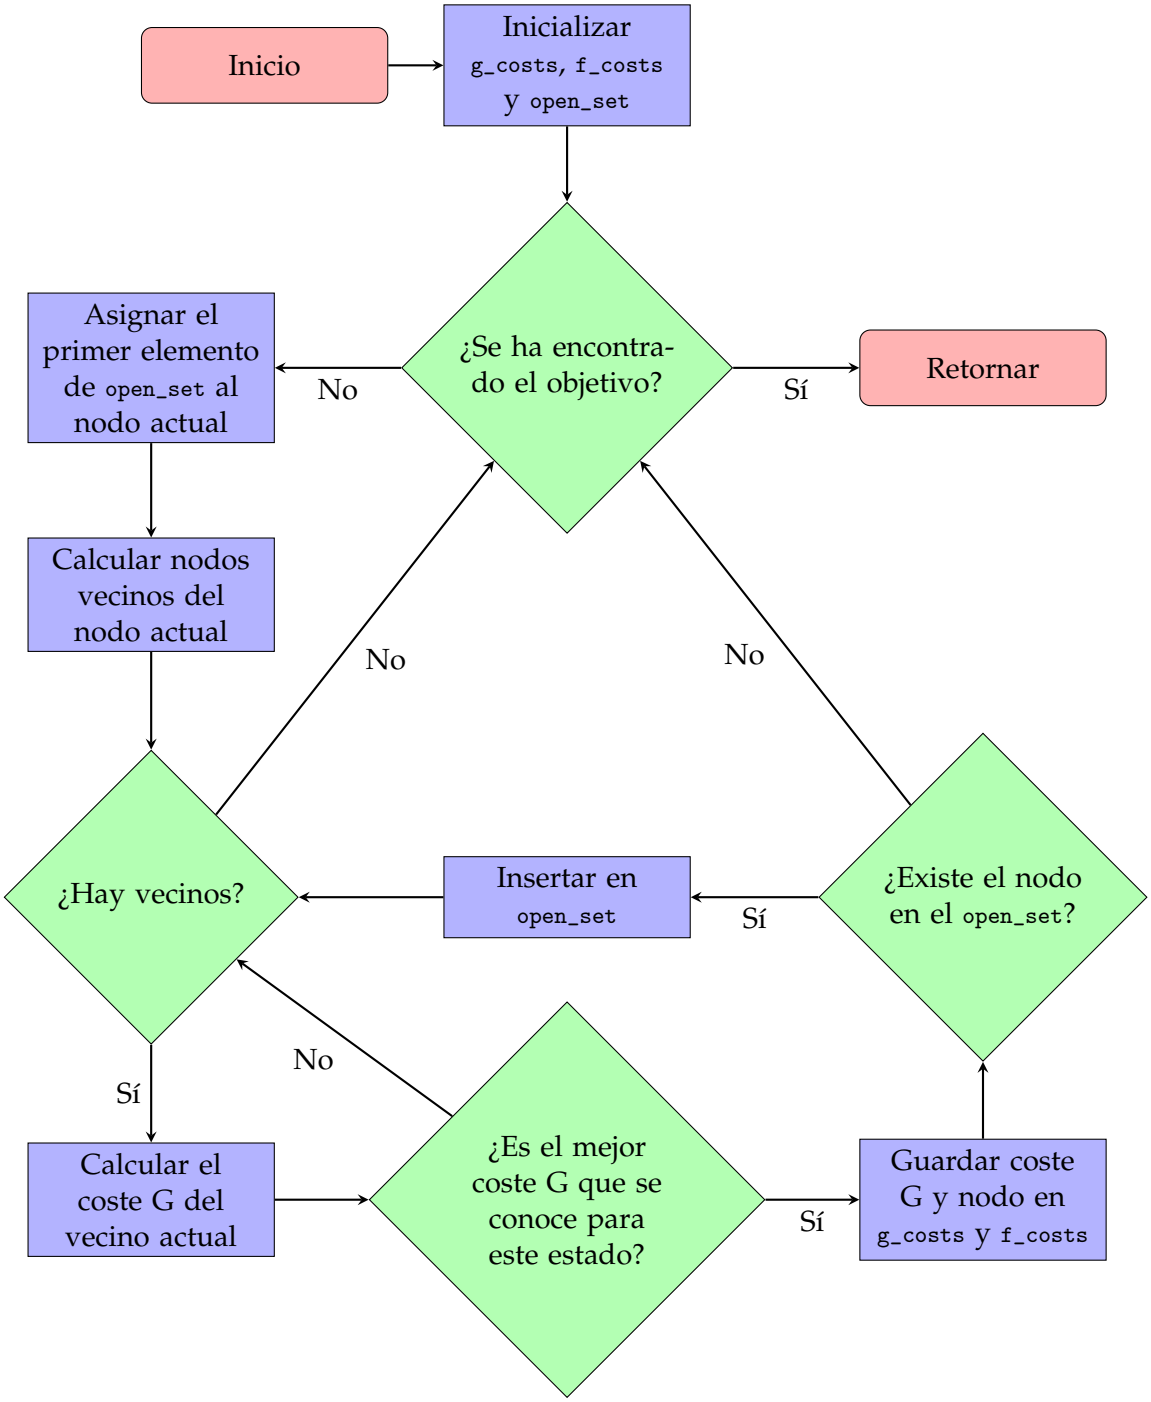

FIGURA 2.2: Representación del algoritmo A*

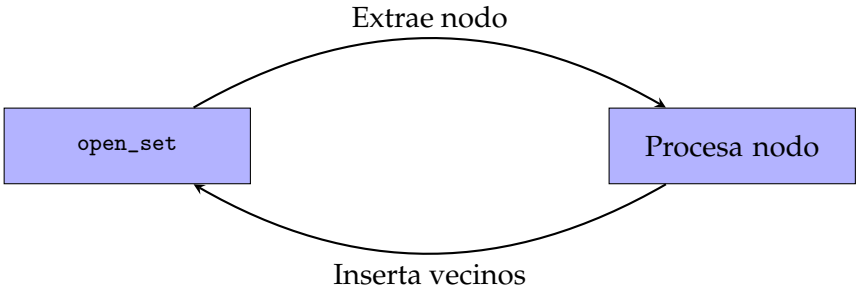

FIGURA 2.3: Representación de la estrategia FCFS

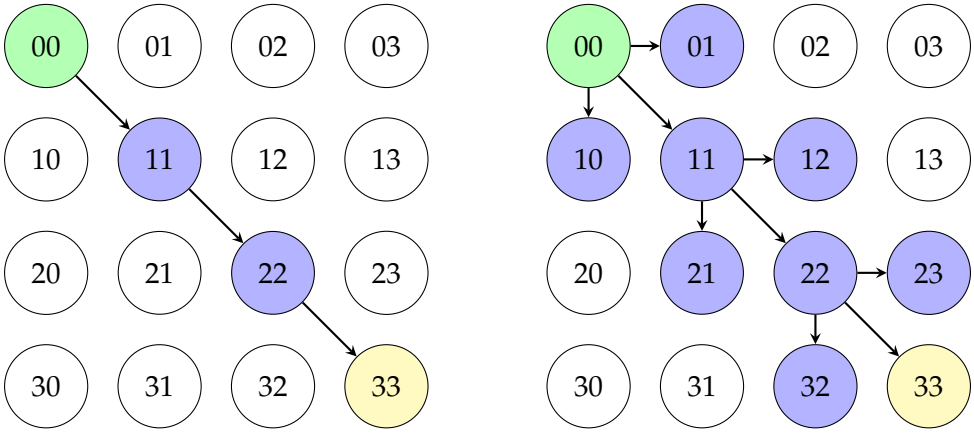

(A) Algoritmo A* monohilo (B) Algoritmo A* multihilo (3 hilos)

FIGURA 2.4: Comparativa entre algoritmos monohilo y multihilo

De cualquier forma, este diseño en particular no tiene por qué reducir el tiempo requerido para hallar un nodo solución, simplemente tiene la oportunidad de reducirlo en algunos casos específicos. Esto se debe a que la única diferencia entre las versiones monohilo y multihilo es que en la multihilo se procesan más nodos en el mismo tiempo. (Véase Figura 2.4)

NOTA

Nótese que este acercamiento no tiene sincronización entre diferentes iteraciones, esto implica que la solución está sujeta a una condición de carrera (i.e. la solución depende de qué hilo finalice primero su ejecución). Por lo que sería posible ejecutar N veces este algoritmo y obtener N soluciones diferentes.

2.5.2.1.1. Secciones críticas

El diseño paralelo propuesto no es sin inconvenientes, su implementación contiene varias secciones críticas que suponen una amenaza para el rendimiento del algoritmo. A continuación se observan cada una de estas secciones y se analizan las razones por las cuales son necesarias.

2.5.2.1.1.1. Variables de control de flujo

Primero, al paralelizar el algoritmo siguiendo esta estrategia, se han añadido variables de control compartidas por todos los hilos que sirven para conocer si se ha resuelto el problema o no (una variable donde se copia el resultado y otra que sirve como *flag*). El acceso a estas variables debe estar controlado para evitar el acceso simultaneo a las mismas. De cualquier forma, es improbable que dos hilos tengan la necesidad de acceder esta sección crítica ya que sólo se ejecuta una vez por lo que los efectos en el rendimiento serán nulos. Sería necesario que dos hilos hallasen dos soluciones diferentes al problema al mismo tiempo.

2.5.2.1.1.2. `open_set`

Segundo, el acceso al `open_set` también debe estar controlado de forma que sólo un hilo pueda interactuar con la estructura de datos compartida. Esta interacción se presenta al menos en dos instancias por cada iteración del bucle principal: una primera vez para acceder al nodo a procesar y otra para insertar los nuevos vecinos. Si bien la obtención del nodo a procesar se realiza en $O(1)$ ya que el `open_set` está ordenado y siempre se accede al nodo en la cabeza de la lista, la inserción de vecinos no corre la misma suerte. Para que la lectura del nodo a procesar sea en $O(1)$ el `open_set` se mantiene ordenado, esto implica que la inserción ser haría en $O(n)$ [4].

NOTA

La complejidad de la sección crítica en la que se insertan elementos en el `open_set` tiene como factor la longitud del `open_set`. Esto es, a mayor tamaño tenga el `open_set`, mayor tiempo será necesario para resolver la sección crítica.

Nótese que a medida que avanza el programa, el tamaño del `open_set` crece, incrementando la duración de la sección crítica y reduciendo la paralelización del algoritmo.

2.5.2.2. Batch Solver

La siguiente estrategia es una evolución del FCFS Solver anterior, utiliza el mismo principio (los hilos exploran nodos del `open_set` a medida que éste se va llenando), pero en este caso se implanta una barrera de sincronización en cada iteración. Esta barrera obliga a los hilos a esperar al resto de sus compañeros antes de extraer otro nodo del `open_set`.

La diferencia más notable entre este acercamiento y el anterior es que las secciones críticas se ven reducidas porque las secciones paralelas son menores. Además, al sincronizar los hilos en cada iteración, ahora no existe ninguna condición de carrera que pueda alterar el resultado, por lo que para el mismo problema este algoritmo siempre retornará el mismo resultado y utilizará la misma ruta para llegar a él.

Se utiliza un `std::vector<State>` para almacenar los nodos a explorar por cada hilo y un `std::vector<std::vector<State>>` para que cada hilo almacene los vecinos que ha

[4] Esta implementación utiliza iteradores y `std::deque<T>` para hallar la posición de cada nuevo elemento e insertarlo en el mismo barrido.

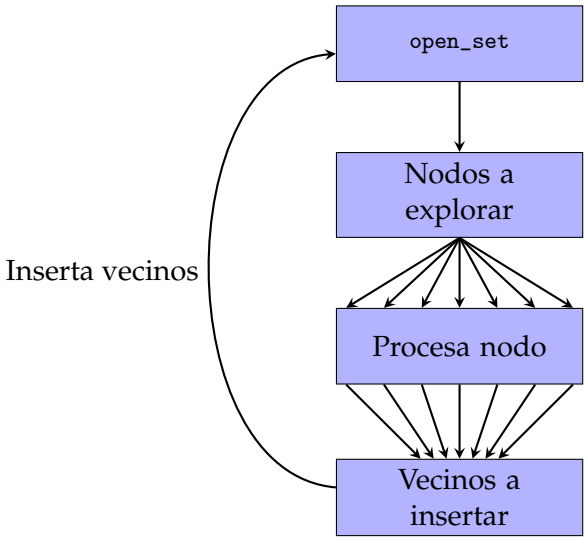

FIGURA 2.5: Representación de la estrategia Batch

encontrado. Cada uno de estos vectores tiene una longitud igual al número de hilos de forma que el hilo con ID *N* tiene asignada la posición *N* de cada vector.

2.5.2.2.1. Secciones críticas

A diferencia de la estrategia FCFS, no es posible que dos hilos accedan al mismo recurso de forma simultánea. Las únicas estructuras de datos compartidas (los dos `std::vector`) ofrecen a los hilos un índice privado al que acceder.

Las secciones críticas de la estrategia FCFS ahora son ejecutadas por un hilo: una al registrar los nodos a explorar y otra al retirar los vecinos e insertarlos en el `open_set`.

2.5.2.3. Recursive Solver

La estrategia propuesta en [Zag+17] se basa en la ejecución simultánea de varias instancias del algoritmo A* en el mismo problema.

1. Calcular vecinos del estado inicial.
2. Asignar un hilo a cada vecino.
3. Para cada vecino, resolver el problema como si fuese el estado inicial.
4. Recoger resultados obtenidos.
5. Obtener resultado con menor coste.
6. Retornar.

Al igual que la solución por batches, no existe ninguna condición de carrera que permita al algoritmo retornar resultados diferentes en varias ejecuciones. Originalmente cada hilo utiliza sus propias estructuras de datos, por lo que no existen secciones críticas. No obstante, sería posible hacer una versión en la que los distintos hilos compartiesen las estructuras de costes y el `open_set`. Implementar el algoritmo de esta forma añadiría las tediosas secciones críticas que podrían ser más dañinas que beneficiosas.

Este diseño puede ser de gran interés para otros problemas distintos al JSP donde existan varios estados iniciales, ya que sería posible calcular una solución del A* para cada uno de ellos. El algoritmo permitiría conocer el mejor estado inicial así como la ruta a seguir para llegar al estado objetivo.

2.5.3. Hash Distributed A* (HDA*) Solver

El algoritmo propuesto en [KFB09] utiliza tantos `open_set` como hilos y una función hash para asignar cada nodo a uno de los `open_set`. Cada hilo es 'propietario' de uno de los `open_set` y por consecuente, de los nodos que estén contenidos dentro del mismo. Cada hilo está encargado de explorar los nodos de su `open_set` y de añadir sus vecinos al `open_set` correspondiente.

El rendimiento de este acercamiento depende en gran medida de la función hash que se utilice para distribuir a los diferentes nodos. Una función hash que no sea uniforme [5] distribuirá los nodos de forma poco equitativa sobrecargando algunos hilos. Por otro lado, al utilizar varios `open_set`, el tiempo de inserción es menor porque tienen un menor tamaño.

[5] Una función hash es uniforme si los valores que retorna tienen la misma probabilidad de ser retornados.

Capítulo 3

Experimentos

Trabajo y Resultados

3.1. Conjuntos de datos

Los diferentes conjuntos de datos utilizados para medir el rendimiento de las diferentes implementaciones han sido obtenidos de (HTTP) Jobshop Instances o diseñados a mano.

3.1.1. *Jobshop Instances*

3.1.2. Personalizados

3.2. Método de medición

Todas las versiones imprimen por salida estándar datos que posteriormente son procesados en formato CSV:

- Lenguaje
- Número de hilos
- Porcentaje del trabajo resuelto
- Trabajos
- Tareas
- Trabajadores
- Tiempo de ejecución
- Planificación
- *Makespan*

La alta complejidad del JSP implica que un mínimo aumento en el tamaño del problema puede implicar que el algoritmo no finalice su ejecución en un tiempo

polinomial. Por ello, en lugar de tomar una única medición al inicio y final de la ejecución se ha optado por utilizar un objeto personalizado que toma mediciones en intervalos predefinidos. De esta forma, de una única ejecución se podría obtener:

- Tiempo de inicio.
- Tiempo necesario para resolver el 10% del problema.
- Tiempo necesario para resolver el 20% del problema.
- ...
- Tiempo necesario para resolver el 90% del problema.
- Tiempo necesario para resolver el 100% del problema.

Se utiliza una función que se encarga de tomar una medición de tiempo antes y después de iniciar el algoritmo.

```
1  class Chronometer
2  {
3  private:
4      std::chrono::_V2::system_clock::time_point m_start_time;
5      std::map<unsigned short, bool> m_goals;
6      std::map<unsigned short, double> m_times;
7      std::string m_solver_name;
8
9  public:
10     Chronometer() : Chronometer(
11         std::map<unsigned short, bool>(),
12         "Unknown Solver") {}
13     explicit Chronometer(
14         const std::map<unsigned short, bool> &goals,
15         std::string const &solver_name) : m_goals(goals),
16                                           m_solver_name(solver_name) {}
17
18     void start()
19     {
20         this->m_start_time = std::chrono::high_resolution_clock::now();
21     }
22     std::chrono::duration<double> time() const
23     {
24         return (
25             std::chrono::high_resolution_clock::now() -
26             this->m_start_time
27         );
28     }
29
30     void process_iteration(const State &state);
31     void log_timestamp(unsigned short goal, const State &state);
32     void enable_goals();
33     std::map<unsigned short, double> get_timestamps() const;
34 };
```

Esta clase se utiliza para tomar las mediciones de todas las iteraciones [1] y posteriormente estos datos se utilizan para calcular tiempos medios de ejecución, máximos y mínimos.

[1] Ignorando la primera para calentar la caché

3.3. Resultados

3.4. Análisis

Capítulo 4

Conclusiones

Observaciones y Trabajos futuros

Apéndice A

Código Fuente

Apéndice B

Resultados y Métricas

Bibliografía

[Man67] G. K. Manacher. «Production and Stabilization of Real-Time Task Schedules». En: *J. ACM* 14.3 (1967), 439–465. ISSN: 0004-5411. DOI: 10.1145/321406.321408. URL: https://doi.org/10.1145/321406.321408.

[HNR68] Peter E. Hart, Nils J. Nilsson y Bertram Raphael. «A Formal Basis for the Heuristic Determination of Minimum Cost Paths». En: *IEEE Transactions on Systems Science and Cybernetics* (jul. de 1968), págs. 100 -107. URL: https://ieeexplore.ieee.org/abstract/document/4082128/authors#authors.

[Nil69] Nils J. Nilsson. «Problem solving methods in Artificial Intelligence». En: *Stanford Research Institute* (1969). URL: https://stacks.stanford.edu/file/druid:xw061vq8842/xw061vq8842.pdf.

[Yan77] Yoo Baik Yang. «Methods and Techniques used for Job Shop Scheduling». Methods and Techniques, Analytical Techniques. Masters Thesis. College of Engineering of Florida Technological University, 1977. URL: https://stars.library.ucf.edu/cgi/viewcontent.cgi?article=1389&context=rtd.

[Nil84] Nils J. Nilsson. «Shakey the Robot». En: *SRI International* (1984). URL: http://ai.stanford.edu/~nilsson/OnlinePubs-Nils/shakey-the-robot.pdf.

[KTM99] Joachim Käschel, Tobias Teich y B. Meier. «Algorithms for the Job Shop Scheduling Problem - a comparison of different methods». En: (ene. de 1999). URL: https://www.researchgate.net/publication/240744093_Algorithms_for_the_Job_Shop_Scheduling_Problem_-_a_comparison_of_different_methods.

[KFB09] Akihiro Kishimoto, Alex Fukunaga y Adi Botea. «Scalable, Parallel Best-First Search for Optimal Sequential Planning». En: *Proceedings of the International Conference on Automated Planning and Scheduling* 19.1 (2009), págs. 201-208. DOI: 10.1609/icaps.v19i1.13350. URL: https://ojs.aaai.org/index.php/ICAPS/article/view/13350.

[MSV13] Carlos Mencia, Maria R. Sierra y Ramiro Varela. «Depth-first heuristic search for the job shop scheduling problem». En: *Annals of Operations Research* (jul. de 2013). URL: https://link.springer.com/article/10.1007/s10479-012-1296-x#citeas.

[Kon14] Sai Varsha Konakalla. «A Star Algorithm». En: *Indiana State University* (dic. de 2014), pág. 4. URL: http://cs.indstate.edu/~skonakalla/paper.pdf.

[WH16] Ariana Weinstock y Rachel Holladay. «Parallel A* Graph Search». En: 2016. URL: https://api.semanticscholar.org/CorpusID:218446573.

[Zag+17] Soha S. Zaghloul et al. «Parallelizing A* Path Finding Algorithm». En: *International Journal Of Engineering And Computer Science* (sep. de 2017), 22469–22476. ISSN: 2319-7242. DOI: 0.18535/ijecs/v6i9.13. URL: https://www.ijecs.in/index.php/ijecs/article/download/2774/2563/.

[ZJW20] Yuzhi Zhou, Xi Jin y Tianqi Wang. «FPGA Implementation of A* Algorithm for Real-Time Path Planning». En: *International Journal of Reconfigurable Computing* (2020). DOI: 10.1155/2020/8896386. URL: https://doi.org/10.1155/2020/8896386.

[BC22] Cristina Ruiz de Bucesta Crespo. «Resolución del Job Shop Scheduling Problema mediante reglas de prioridad». En: *Universidad de Oviedo* (2022). URL: https://digibuo.uniovi.es/dspace/bitstream/handle/10651/62015/TFG_CristinaRuizdeBucestaCrespo.pdf?sequence=10.

Índice alfabético

A*: Coste F, 6
A*: Coste G, 6
A*: Coste H, 6
A*: Estado, 5
A*: Lista de prioridad, 7
A*: Sucesores / Vecinos / Hijos, 6
Alcance, 3
Algoritmo A*, 5
Arquitectura x86, 8

Batch Solver, 15

Estado del arte, 1

First Come First Serve (FCFS) Solver, 12

FPGA, 8

Hash Distributed A* (HDA*) Solver, 17

Job Shop Scheduling Problem, 4

Objeto de la investigación, 1

Recursive Solver, 16
Requisitos, 2

State, 9

Task, 9